

Il y a deux types d'algorithme de classification :

- Classification supervisée : on connaît les classes de certaines données (données d'entraînement) qui permettent de prédire la classe d'une nouvelle donnée. Exemples : k plus proches voisins, ID3.
- Classification non supervisée : Il n'y a pas de donnée d'entraînement et l'ensemble des classes possibles n'est pas connu à l'avance. Exemples : k -moyennes, classification hiérarchique ascendante.

I Algorithme des k -moyennes (k -means)

On note d une distance (par exemple la distance euclidienne) et k un entier.

Définition : Centre

Le centre (ou : isobarycentre) d'un ensemble de vecteurs $X = \{x_1, \dots, x_n\}$ est le vecteur

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i$$

Définition : Inertie

On veut trouver une partition \mathcal{P} de X en k sous-ensembles X_1, \dots, X_k (classes ou *clusters*) minimisant l'inertie :

$$I(\mathcal{P}) = \sum_{i=1}^k \sum_{x \in X_i} d(x, \bar{X}_i)^2$$

Plus l'inertie est petite, plus les données sont proches au sein de leur classe et plus le partitionnement est bon.

Algorithme des k -moyennes

Entrée : Des données X , un entier k

Sortie : Une partition de X en k classes

Soient c_1, \dots, c_k des vecteurs (centres) choisis aléatoirement

Tant que les centres ont changé :

Associer chaque donnée x à la classe X_i telle que $d(x, c_i)$ soit minimum

Recalculer les centres des classes $c_i = \bar{X}_i$

Renvoyer X_1, \dots, X_k

Remarques :

- On peut choisir les centres initiaux aléatoirement dans R^p ou parmi X .
- k est le nombre de classes dans l'algorithme des k -moyennes alors que c'est le nombre de voisins dans l'algorithme des k plus proches voisins.
- Le problème de décision consistant à déterminer s'il existe une partition d'inertie inférieure à un seuil est NP-complet.

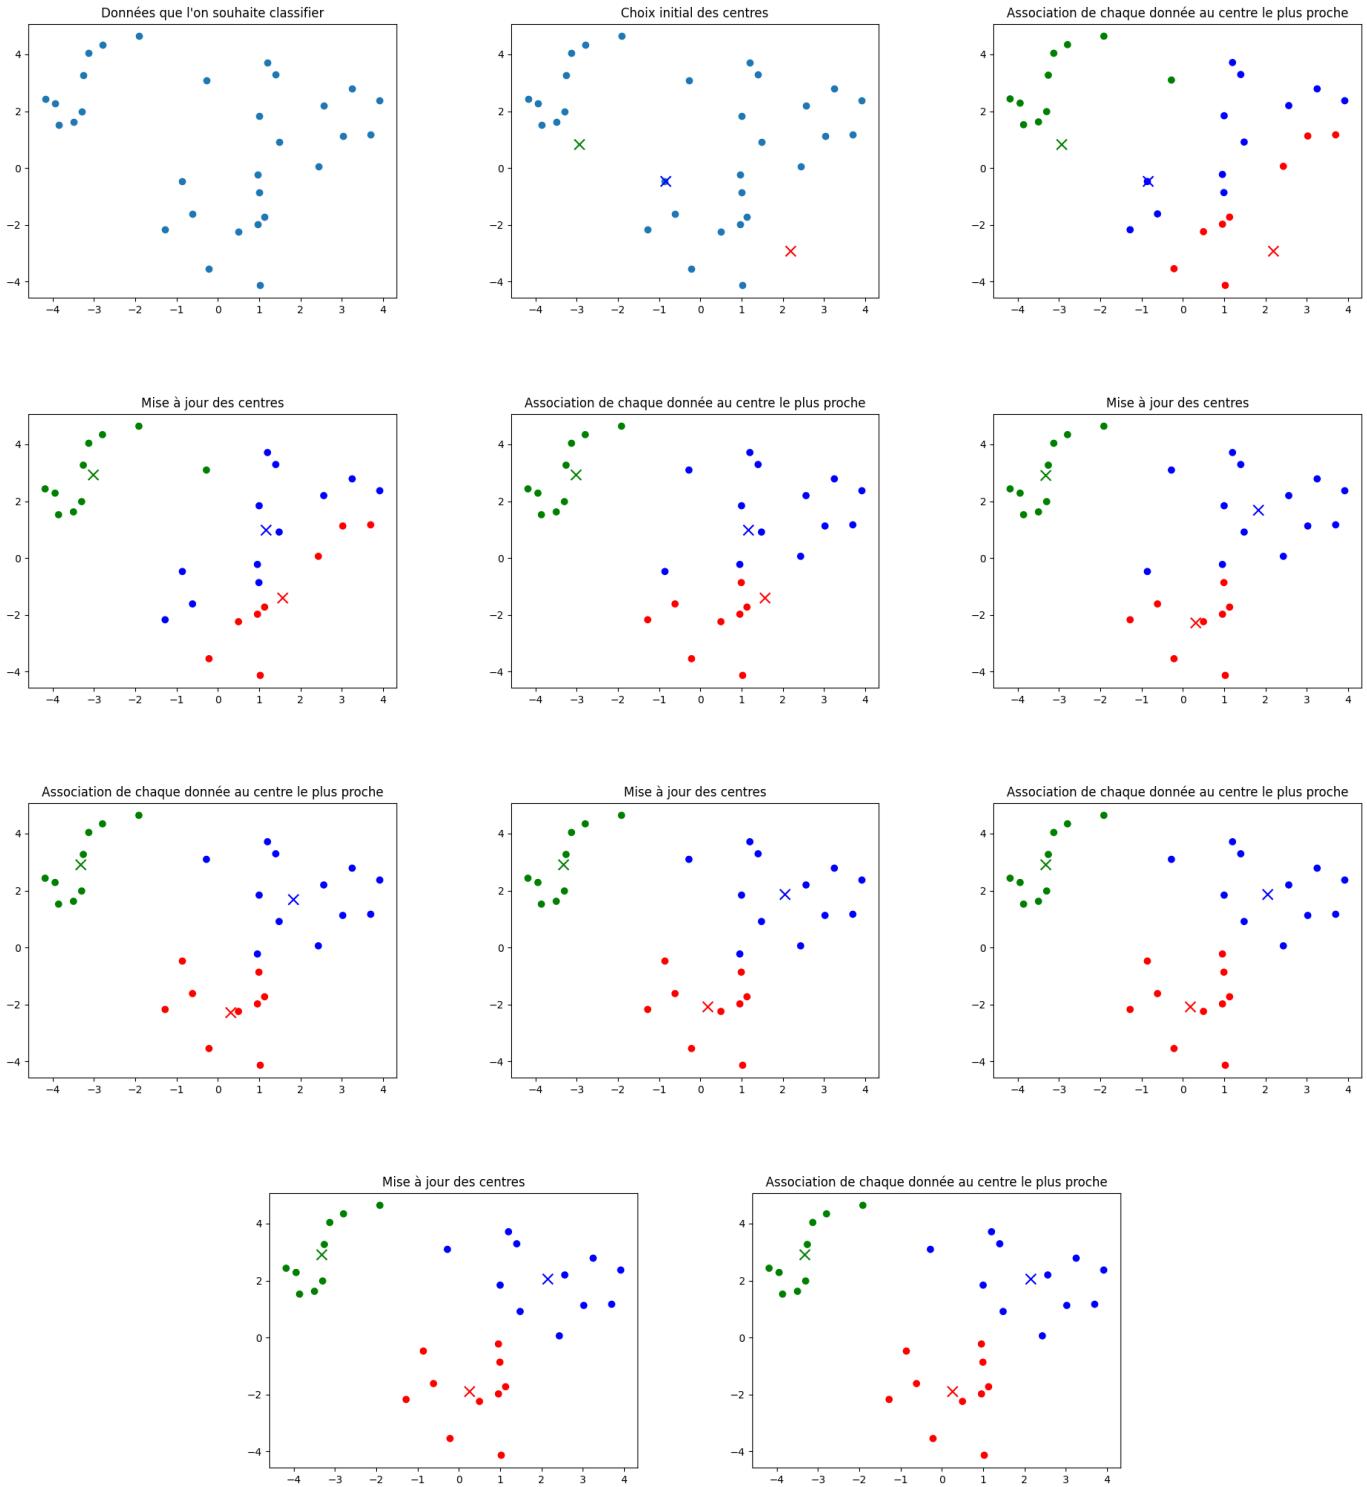
I.1 Terminaison (HP)

Théorème

L'algorithme des k -moyennes termine (pas de boucle infinie).

Preuve : Il existe un nombre fini de partitions de X en k classes, donc l'inertie I ne peut prendre qu'un nombre fini de valeurs. De plus, I diminuant strictement à chaque itération (c'est un variant) :


- Réassigner x de X_i à X_j si $d(x, c_i) > d(x, c_j)$ fait diminuer I .
- Recalculer les centres des classes fait diminuer I car $f : y \mapsto \sum_{x \in X} d(x, y)^2$ est minimum pour $y = \bar{X}$.



Exemple d'exécution de l'algorithme des k -moyennes

I.2 Choisir k

On peut calculer l'inertie obtenue pour différentes valeurs de k . La méthode du coude consiste à choisir la plus grande valeur de k pour laquelle l'inertie diminue de façon significative.



On choisit $k = 3$ ou $k = 4$.

I.3 Non optimalité


L'algorithme des k -moyennes converge toujours vers un minimum local, mais pas forcément vers un minimum global de l'inertie.

Exercice 1.

Donner un exemple d'exécution de l'algorithme des k -moyennes qui ne donne pas une partition d'inertie minimum.

I.4 Limites


L'algorithme des k -moyennes ne marche que sur des données linéairement séparables (pouvant être séparées par un hyperplan).



L'algorithme des k -moyennes ne permettrait pas de classifier correctement ces données.

I.5 Interprétations

Les centres obtenus à la fin de l'algorithme donnent des informations sur les constituants des classes.



Centres obtenus avec $k = 10$ sur des chiffres manuscrits

II Classification hiérarchique ascendante (CHA)

Classification hiérarchique ascendante

Entrée : Des données X

Sortie : Une partition de X en classes

Mettre chaque $x \in X$ dans une classe différente

Tant que nécessaire :

 └ Fusionner les deux classes les plus proches

Renvoyer Les classes obtenues

On peut choisir d'arrêter l'algorithme à un certain nombre de classes ou quand la distance minimum entre deux classes est supérieure à un certain seuil.

Exemples de distances entre classes A et B :

1. Distance minimum : $\min_{a \in A, b \in B} d(a, b).$
2. Distance maximum : $\max_{a \in A, b \in B} d(a, b).$
3. Distance moyenne : $\frac{1}{|A||B|} \sum_{a \in A, b \in B} d(a, b).$

Exercice 2.

Appliquer l'algorithme de classification hiérarchique ascendante sur les données suivantes en dessinant le dendrogramme obtenu. On utilisera la distance 1.

