

I Alphabet et mot

Définition : Alphabet

Un alphabet est un ensemble Σ fini, dont les éléments sont des lettres.

Définition : Mot

Un mot m sur un alphabet Σ est une suite finie $m_1, \dots, m_n$ de lettres de Σ , et on note $m = m_1 \cdots m_n$.

n est la longueur de m , qu'on note $|m|$.

Le mot vide (ne contenant aucune lettre) est noté ε .

Attention : ε est un mot, pas une lettre.

On définit aussi :

- Σ^* : l'ensemble des mots sur Σ .
- $\Sigma^+ = \Sigma^* \setminus \{\varepsilon\}$.
- Σ^n l'ensemble des mots de longueur n sur Σ .

Définition : Égalité de mots

Deux mots $u = u_1 \cdots u_n$ et $v = v_1 \cdots v_p$ sur le même alphabet Σ sont égaux s'ils ont la même longueur ($n = p$) et si, pour tout $i \in \{1, \dots, n\}$, $u_i = v_i$.

Définition : Concaténation et puissance

La concaténation de deux mots $u = u_1 \cdots u_n$ et $v = v_1 \cdots v_p$ est :

$$uv = u_1 \cdots u_n v_1 \cdots v_p$$

Elle est aussi parfois notée $u \cdot v$.

Si u est un mot, on définit $u^0 = \varepsilon$ et $u^k = \underbrace{u \cdots u}_{k \text{ facteurs}}$.

Exercice 1.

Soient Σ un alphabet, $a, b \in \Sigma$ et $u \in \Sigma^*$. On suppose $au = ub$.

Montrer que $a = b$ et qu'il existe $k \in \mathbb{N}$ tel que $u = a^k$.

Définition : Préfixe, suffixe, facteur, sous-mot

Soient u et m deux mots sur Σ .

- u est un préfixe de m s'il existe un mot v tel que $m = uv$.
- u est un suffixe de m s'il existe un mot v tel que $m = vu$.
- u est un facteur (*substring* en anglais) de m s'il existe des mots v, w tels que $m = vuw$.
- u est un sous-mot (*subsequence* en anglais) de m si u est une sous-suite (ou : suite extraite) de m .

Exemple : abc est un sous-mot de $aabacb$, mais pas un facteur.

I.1 Implémentation d'un mot avec une chaîne de caractères

Rappels d'utilisation d'une chaîne de caractères (**string**) :

```

let s = "abc" (* définit une chaîne de caractères *)
s.[1] (* donne 'b' *)
String.length s (* donne 3 *)
"abc" ^ "def" (* concaténation *)

```

Remarque : contrairement à **array**, le type **string** est immuable (on ne peut pas modifier un caractère d'une chaîne de caractères).

Exercice 2.

Écrire une fonction `sous_mot` : **string** -> **string** -> **bool** qui teste si un mot est un sous-mot d'un autre, en complexité linéaire.

II Langage

Définition : Langage

Un langage L sur un alphabet Σ est un ensemble de mots sur Σ .

De façon équivalente, L est un langage si $L \subseteq \Sigma^*$ ou encore $L \in \mathcal{P}(\Sigma^*)$.

Exemples :

1. L'ensemble $L_0 = \{\varepsilon, a, bab\}$ sur $\Sigma = \{a, b\}$.
2. L'ensemble L_1 des mots d'un dictionnaire ne contenant que des lettres minuscules non accentuées, sur $\Sigma = \{a, b, \dots, z\}$.
3. L'ensemble L_2 des formules arithmétiques sur $\Sigma = \{0, \dots, 9, +, -, /, *, (,)\}$.
4. L'ensemble L_3 des programmes OCaml sur $\Sigma = \{a, \dots, z, _, !, <, >, \dots\}$.

Définition : Concaténation

Soient L_1 et L_2 deux langages sur le même alphabet. La concaténation $L_1 L_2$ de L_1 et L_2 est définie par :

$$L_1 L_2 = \{m_1 m_2 \mid m_1 \in L_1, m_2 \in L_2\}$$

$L_1 L_2$ est donc l'ensemble des mots obtenus par concaténation d'un mot de L_1 et d'un mot de L_2 .

Exercice 3.

1. Soit $L_1 = \{a, ab\}$ et $L_2 = \{\varepsilon, b, bba\}$. Déterminer $L_1 L_2$.
2. Quel lien a-t-on entre $|L_1 L_2|$ et $|L_1| |L_2|$, dans le cas général ?

Exercice 4.

1. La concaténation de deux langages est-elle commutative ? Associative ? _____
2. Quel est l'élément neutre de la concaténation ? L'élément absorbant ? _____

La concaténation est distributive par rapport à l'union : $L_1(L_2 \cup L_3) = L_1L_2 \cup L_1L_3$.

Définition : Puissance

On définit la puissance L^n du langage L par récurrence :

$$\begin{aligned} L^0 &= \{\varepsilon\} \\ L^n &= L^{n-1}L, \text{ pour } n \geq 1 \end{aligned}$$

Dit autrement : $L^n = \underbrace{L \cdot \dots \cdot L}_{n \text{ facteurs}} = \{m_1 \dots m_n \mid m_1 \in L, \dots, m_n \in L\}$.

Exemple : Σ^n est l'ensemble des mots de longueur n sur l'alphabet Σ .

Exercice 5.

Soit L un langage.

1. Montrer que $L \subseteq L^2$ si et seulement si $L = \emptyset$ ou $\varepsilon \in L$.
2. Comparer L^2 et $\{u^2 \mid u \in L\}$.

Définition : Étoile de Kleene

On définit l'étoile (de Kleene) L^* d'un langage L par :

$$L^* = \bigcup_{k \in \mathbb{N}} L^k$$

L^* est donc l'ensemble des mots obtenus par concaténation d'un nombre quelconque de mots de L .

Remarque : L^* contient toujours ε , car $L^0 = \{\varepsilon\}$.

Exercice 6.

Montrer que $(L^*)^* = L^*$.

III Langages réguliers

Définition : Langage régulier (ou : langage rationnel) ♥

L'ensemble $\text{Reg}(\Sigma)$ des langages réguliers sur Σ est défini par :

- $\text{Reg}(\Sigma)$ contient tous les langages finis.
- $\text{Reg}(\Sigma)$ est stable par union, concaténation et étoile de Kleene.
- $\text{Reg}(\Sigma)$ est le plus petit ensemble de langages ayant ces propriétés (si P est un ensemble de langages contenant les langages finis et stable par union, concaténation et étoile de Kleene, alors $\text{Reg}(\Sigma) \subseteq P$).

Définition : Définition inductive équivalente ♥

- Tout langage fini est régulier.
- Si L_1 et L_2 sont réguliers, alors $L_1 \cup L_2$ est régulier.
- Si L_1 et L_2 sont réguliers, alors $L_1 L_2$ est régulier.
- Si L est régulier, alors L^* est régulier.

Par récurrence immédiate, si $L_1, \dots, L_n$ sont réguliers, alors $L_1 \cup \dots \cup L_n$ et $L_1 L_2 \dots L_n$ sont réguliers.

Attention :

- Une union infinie de langages réguliers n'est pas forcément régulière.
- Un langage particulier n'est pas forcément stable par concaténation.

Exemples :

1. Soit m un mot. Alors $\{m\}$ est fini, donc régulier ; on le note aussi m par abus de notation.
2. Σ est fini, donc régulier. Par conséquent, Σ^* est également régulier.
3. Soit m un mot. L'ensemble des mots ayant m comme facteur est égal à $\Sigma^* m \Sigma^*$; c'est donc un langage régulier.
4. Soit $m = m_1 \dots m_n$ un mot. L'ensemble des mots ayant m comme sous-mot est égal à $\Sigma^* m_1 \Sigma^* m_2 \dots \Sigma^* m_n \Sigma^*$; c'est donc un langage régulier.

Exercice 7.

Montrer que les langages suivants sont réguliers sur $\Sigma = \{a, b\}$:

1. Mots commençant par a : _____
2. Mots commençant par a et finissant par b : _____
3. Mots de longueur paire : _____
4. Mots de longueur impaire : _____

IV Expressions régulières

Les expressions régulières sont une notation plus concise pour représenter un langage régulier :

Définition : Expression régulière (ou : expression rationnelle)

L'ensemble $\mathcal{R}(\Sigma)$ des expressions régulières sur un alphabet Σ est le plus petit ensemble vérifiant :

- $\forall a \in \Sigma, a \in \mathcal{R}(\Sigma)$
- $\emptyset \in \mathcal{R}(\Sigma), \varepsilon \in \mathcal{R}(\Sigma)$
- $\forall e_1, e_2 \in \mathcal{R}(\Sigma), (e_1 | e_2) \in \mathcal{R}(\Sigma)$ et $(e_1 e_2) \in \mathcal{R}(\Sigma)$
- $\forall e \in \mathcal{R}(\Sigma), e^* \in \mathcal{R}(\Sigma)$

Remarque : On utilise parfois $+$ à la place de $|$.

On peut les représenter informatiquement par le type OCaml :

```

type 'a regexp = (* 'a est le type des lettres de l'alphabet *)
| Vide | Epsilon | L of 'a (* L a désigne la lettre a *)
| Union of 'a regexp * 'a regexp
| Concat of 'a regexp * 'a regexp
| Etoile of 'a regexp

```

Définition : Langage d'une expression régulière

Si e est une expression régulière, on définit son langage associé $L(e)$ récursivement :

- $L(a) = \{a\}$ si $a \in \Sigma$
- $L(\emptyset) = \emptyset$, $L(\varepsilon) = \{\varepsilon\}$
- $L(e|e') = L(e) \cup L(e')$
- $L(ee') = L(e)L(e')$
- $L(e^*) = L(e)^*$

Remarques :

- Par abus de langage, on confond souvent e et $L(e)$.
- Une expression régulière décrit de façon compacte la construction d'un langage régulier à l'aide de l'union, de la concaténation et de l'étoile de Kleene. Cette notation est à la base des moteurs d'expressions régulières utilisés dans les éditeurs de texte.

Théorème

Soit L un langage. L est régulier si et seulement s'il existe une expression régulière e telle que $L = L(e)$.

Exemples :

- $(a|b)^*$: ensemble de tous les mots ($= \Sigma^*$).
- $(a|b)^*bb$: mots finissant par bb .

Exercice 8.

Donner une expression régulière pour les langages suivants, sur $\Sigma = \{a, b\}$:

1. Mots contenant au plus un a : _____
2. Mots dont la longueur est congrue à 1 modulo 3 : _____
3. Mots contenant un nombre pair de a : _____
4. Mots contenant un nombre impair de a : _____
5. Écritures en base 2 des entiers divisibles par 4 : _____

V Équivalence d'expressions régulières

Définition : Équivalence d'expressions régulières

Deux expressions régulières e_1 et e_2 sont dites équivalentes, ce que l'on note $e_1 \equiv e_2$, si elles définissent le même langage, c'est-à-dire si $L(e_1) = L(e_2)$.

Exemple : $(ab)^*a \equiv a(ba)^*$.

Théorème

Pour des expressions régulières e , e_1 , e_2 et e_3 :

1. $e\emptyset \equiv$ _____
2. $e\varepsilon \equiv$ _____
3. $e|\emptyset \equiv$ _____
4. $\emptyset^* \equiv$ _____
5. $\varepsilon^* \equiv$ _____
6. $(e_1|e_2)e_3 \equiv$ _____
7. $e_1(e_2e_3) \equiv$ _____

VI Induction structurelle

Théorème : Induction structurelle sur les langages réguliers ♡

Soit $\mathcal{P}(L)$ une propriété sur les langages réguliers L telle que :

- $\mathcal{P}(L)$ est vraie pour les langages L finis (cas de base)
- $\mathcal{P}(L_1) \wedge \mathcal{P}(L_2) \implies \mathcal{P}(L_1 L_2)$
- $\mathcal{P}(L_1) \wedge \mathcal{P}(L_2) \implies \mathcal{P}(L_1 \cup L_2)$
- $\mathcal{P}(L) \implies \mathcal{P}(L^*)$

Alors $\mathcal{P}(L)$ est vraie pour tout langage régulier L .

Preuve : _____

Théorème : Induction structurelle sur les expressions régulières ♡

Soit $\mathcal{P}(e)$ une propriété sur les expressions régulières telle que :

- $\mathcal{P}(\emptyset)$, $\mathcal{P}(\varepsilon)$ sont vraies (cas de base)
- $\mathcal{P}(a)$ est vraie pour $a \in \Sigma$ (cas de base)
- $\mathcal{P}(e_1) \wedge \mathcal{P}(e_2) \implies \mathcal{P}(e_1 e_2)$
- $\mathcal{P}(e_1) \wedge \mathcal{P}(e_2) \implies \mathcal{P}(e_1 | e_2)$
- $\mathcal{P}(e) \implies \mathcal{P}(e^*)$

Alors $\mathcal{P}(e)$ est vraie pour toute expression régulière e .

Exercice 9.

Si $m = m_1 \cdots m_n$ est un mot, on définit son miroir $\tilde{m} = m_n \cdots m_1$.

Si L est un langage, on définit son miroir $\tilde{L} = \{\tilde{m} \mid m \in L\}$.

1. Donner une expression régulière du miroir de $a(a|b)^*b$.
2. Soit e une expression régulière de langage L . Montrer que $\tilde{L}$ est régulier.
3. Écrire une fonction OCaml `miroir : 'a regexp -> 'a regexp` renvoyant le miroir d'une expression régulière.

[illegible]